

PAPERPILOT

原文证据驱动的 科研助手 Agent 系统

面向 PDF 细粒度解析、抗幻觉问答、多文推理、双语阅读、引用图谱与研究材料生成的可复现系统

文档状态	比赛技术文档排版草稿
仓库	github.com/Sana-114/PDF-AGENT
在线演示	临近提交时部署并补充
版本说明	正式提交前记录 Git Tag 与 Commit SHA

2026 年 9 月 · 排版初稿

目录

01	摘要
02	1. 项目概述
03	2. 系统总体架构
04	3. PDF 管理与细粒度解析
05	4. 抗幻觉 RAG 与多文推理
06	5. 版式感知阅读与翻译
07	6. 检索推荐、引用图谱与研究综述
08	7. 学术写作与数据可视化
09	8. AI 技术选型与优化策略
10	9. 测试与验证
11	10. 部署、安全与可复现性
12	11. 创新点
13	12. 已知边界与后续计划
14	13. 成品 PDF 编排建议
15	14. 仓库内参考资料

摘要

PaperPilot 面向论文阅读、证据问答和研究材料整理，覆盖 PDF 管理与解析、单篇及多篇 RAG、版式感知阅读与翻译、论文检索推荐、局域引用图谱和学术写作可视化六类任务。系统不把大语言模型直接当作事实数据库，而是先将 PDF 解析为带页码、块编号和坐标的 Document AST，再经过混合检索、候选重排、证据门控和引用白名单生成回答。最终结论可回到 PDF 原页高亮；证据不足时返回拒答或抽取式结果。

系统采用 Next.js、FastAPI、Celery、PostgreSQL、Qdrant 与 Docker Compose 构建。标准模式使用 BGE-M3、BGE Reranker 与 DeepSeek Flash，轻量模式使用确定性 Hash-Ngram 与 BM25，便于低资源环境启动和故障演示。当前版本已经用真实 Transformer、BERT、GPT、ResNet 与 Vision Transformer 论文完成跨文献问答、数值事实、拒答和 PDF 锚点验收；同时完成 541 页长文档断点续跑和扫描替代样本 OCR 测试。组委会原始扫描件、公网服务器、域名及最终材料仍需在提交前完成复验和上线。

关键词：科研 Agent；PDF 解析；检索增强生成；证据锚点；多文推理；引用图谱；学术翻译

1. 项目概述

1.1 背景与痛点

科研人员面对的困难不只是“读不完”，还包括以下四类断点：

- PDF 的双栏、公式、表格、扫描页和超长篇幅难以统一结构化；
- 通用对话模型会把记忆、推断和论文原文混在一起，答案难以追溯；
- 阅读、翻译、问答、引用关系和写作工具分散，上下文需要重复搬运；
- 新论文追踪与 Future Work 分析容易停留在关键词推荐，缺少局部证据和时间线。

PaperPilot 的设计原则是“先建立可定位证据，再让模型组织答案”。任何用于回答、比较、综述和写作的论文事实，均应尽可能保存文献、页码、Block ID、BBox 和原文摘录。

1.2 建设目标

- 对原生文本、扫描页和长文档建立统一 Document AST；
- 对相同论文的不同版本给出候选提醒、版本建议和可复核差异；
- 实现带原文页码与位置锚点的单篇问答和多篇对比；
- 打通 PDF 阅读、引用跳转、翻译和问答证据；
- 形成检索、追踪、推荐、图谱、综述和 Future Work workflow；
- 让写作框架、References、图表与图注建立在可核验数据之上；
- 同时提供低资源演示模式和比赛标准模式，并保留公网部署门禁。

1.3 六大模块完成状态

模块	当前实现	状态与边界
PDF 管理与解析	单篇/批量上传、CRUD、内容指纹、版本冲突处理、Document AST、OCR、表格/图/公式候选、长文档检查点	主链路已实现；组委会原始扫描件待复验，复杂合并/旋转表格仍需专用适配器
抗幻觉问答	BM25、Qdrant Dense/Sparse、BGE 重排、DeepSeek 生成、引用白名单、数值审计、拒答、多文比较	已用七篇真实论文完成固定金标验收；不宣称任意问题均正确
阅读与翻译	PDF.js、三级目录、BBox 高亮、正文引用与 References 双向跳转、划词翻译、页级双语、同步滚动、整篇翻译、Markdown/HTML 导出	已实现；保持原位版式的双语 PDF 导出尚未实现
检索追踪推荐	题名/DOI/arXiv 检索、开放 PDF 安全导入、参考文献下钻、arXiv 定时刷新、代码链接、点赞/踩画像	已实现基础闭环；当前直接使用 arXiv API 与 Celery Beat，不依赖 Sickle
引用图谱与综述	库内引用匹配、PageRank/入度、基石/桥接/衍生分类、证据综述、时间线与 Future Work	已实现局域图谱；“已解决”只标记为可能有进展，保留人工确认
写作与可视化	Abstract/Introduction/Related Work 框架、真实 References、Mermaid/Graphviz/TikZ/Matplotlib、CSV 折线/柱状/三维雷达图、Figure Caption、学术翻译审校	已实现；References 只使用本地持久化元数据，不接受模型凭空生成

2. 系统总体架构

2.1 分层架构




图 1：系统总体架构（矢量绘制）。

前端只负责交互和可视化，不在浏览器中保存模型密钥。FastAPI 提供文献、问答、推荐、图谱、写作和可视化接口；解析和整篇翻译由 Celery 异步执行；PostgreSQL 保存业务状态，文件卷保存 PDF、AST 与翻译缓存，Qdrant 保存向量索引。公网模式只开放 Caddy 的 80/443，其他服务留在 Docker 内部网络。

2.2 核心数据流



图 2：核心数据流（矢量绘制）。

2.3 Agent Harness 与 Skills

Agent Harness 负责工具编排、证据门控、模型调用和结果校验。Skill Registry 为工具声明 Pydantic 输入 Schema，当前主要能力包括文献概要、目录、表格、图表、公式、参考文献和证据检索。工具返回结构化数据而非自由文本，使后续 Provider 的输入边界可审计。

这里的“Agent”不是无限自治的浏览器机器人，而是受业务流程约束的科研任务编排器：它只能调用已注册工具，只能引用本轮检索得到的证据编号，并把 Trace 返回给界面。

3. PDF 管理与细粒度解析

3.1 解析路由与 Document AST

解析前对均匀抽样页面诊断文本密度，将文件分为 `native_text`、`scanned_image`、`hybrid` 或 `empty`。原生文本使用 PyMuPDF 版式解析；低文本页选择性调用 Tesseract `chi_sim+eng`，避免整本文档重复 OCR。所有路径输出相同的 AST：

```
Document
├─ title / authors / affiliations / abstract
├─ outline[]
├─ pages[].blocks[] # reading_order / page / bbox / block_id
├─ tables[].cells[] # Markdown segments
├─ figures[] / formulas[]
├─ references[]
└─ appendices[]
```

统一 AST 让阅读器、RAG、翻译、图谱和写作不需要分别解析 PDF。页码、BBox 和 Block ID 从解析阶段一直传递到最终回答。

3.2 双栏、表格、图表和公式

- 双栏页面根据几何位置和阅读顺序重排文本块；
- 有框表格分析矢量网格，无框表格要求可信图注和重复列锚点；
- 跨页表格仅在页面相邻、列边界一致且存在续表或重复表头时合并；
- 扫描页在图注附近执行受限栅格分析，避免把整页扫描图当作论文插图；
- 公式保存原文本与位置，并将明确的 Unicode 数学符号规范化为 LaTeX 候选。

公式字段是确定性候选，不冒充数学 OCR 真值。复杂二维分式、矩阵、旋转表格和合并单元格仍是后续适配方向。

3.3 长文档工程策略

Worker 默认每 25 页写入一个原子检查点，Manifest 绑定 PDF SHA-256、解析器版本、页数与批大小。任务中断后只重跑最后一个未完成批次；全部分片合并、数据库 Chunk 与索引提交完成后清理检查点。前端读取 Manifest 展示完成页数，而不是等待整本结束。

真实 541 页教材验收中，系统在 50 页后模拟中断，恢复后的第一个完成事件为第 75 页；最终抽取 1,312,857 字，Python 峰值内存 45.11 MB、进程 RSS 峰值 298.58 MB。该结果证明工程规模和恢复能力，不等同于教材每个表格均被正确解析。

3.4 语义去重与版本演进

正式截图规划

图 3：v7→v1 版本预警、保留建议与修订差异（隐藏本地路径）。

此处将在最终公网版本录制后替换为真实界面截图。

系统先使用文件 SHA-256 识别完全重复，再综合 arXiv ID、题名相似度和正文指纹重合度寻找版本候选。命中后只产生提醒，不自动删除：用户可以保留库中版本、以当前版本替换或两版并存。

版本差异从两个 AST 重建有序正文，输出页数、文本量、结构节点、标题集合和候选增删段落。差异段落保留来源页码与 Block ID，并标记为“可能新增/删除”，避免把词项差异包装为模型语义判断。

4. 抗幻觉 RAG 与多文推理

4.1 检索链路

Question

→ BM25

→ Qdrant Dense/Sparse RRF

→

→ BGE Cross-Encoder

→ Evidence score gate

→ DeepSeek Flash / Extractive Provider

→

→ Answer + Claims + Evidence + Trace

Chunk 不只包含普通正文，还包含摘要、表格、图注、公式和参考文献节点。问题含“表格分数”“完整引用”等意图时，检索器会提高对应节点类型的权重。BGE 或 Qdrant 故障时在线问答可以降级到 BM25，但严格验收要求 retrieval_mode=reranked，不会把降级结果误报为标准模式通过。

4.2 引用白名单

正式截图规划

图 5：多文回答的 Claims、证据编号、页码与 PDF 原页高亮。

此处将在最终公网版本录制后替换为真实界面截图。

模型收到的证据被编号为本轮唯一的 E1...En。结构化输出中的每条 Claim 必须引用允许列表内的编号；未知编号、空引用或低分证据被拒绝。EvidenceAnchor 包含：

- document_id;
- page_number;
- block_ids;
- bbox;
- section;
- 原文摘录与检索阶段。

因此界面不仅能显示“来源”，还可以把用户带回 PDF 具体页面和区域。

4.3 多文比较与数值完整性


多文比较对每篇论文分别检索和重排，再合并为全局证据编号，避免长论文或 Chunk 较多的论文垄断候选池。对于问题中明确枚举的比较维度，系统追加逐维度检索。若用户明确要求参数量、上下文长度等数值，发布前检查回答是否覆盖已经入选且包含精确数值的证据；补充内容仍需通过同一引用与数值白名单。

没有双来源精确数值时，系统不会仅凭背景描述形成精确差异。例如论文没有报告 kg CO₂e 时，回答应说明证据不足，而不是估算排放数字。

4.4 连续问答

会话保存文献范围、用户消息、已验证回答、Claims、Evidence 与 Trace。SSE 先发送检索状态，再分片发送已经完成结构校验的答案，最后持久化消息。当前不是 DeepSeek 上游逐 Token 直传，而是“先校验、后渐进展示”，优先保证最终回答可恢复和可审计。

5. 版式感知阅读与翻译



此处将在最终公网版本录制后替换为真实界面截图。

PDF.js 阅读器按需加载页面并提供缩放、翻页和三级目录。问答证据的 PDF 点坐标被转换为百分比覆盖层，缩放后仍与原文对齐。无 BBox 时只执行页码定位，并明确提示没有区域高亮。

正文数字引用与 References 使用 AST 中的真实标签连接。用户从 [11] 跳到条目后，可以返回原点击位置，也可以浏览同一文献的上一处/下一处引用。未知标签不生成链接，从而降低公式编号被误识别为引用的风险。

翻译包含三条路径：

- 划词/选段翻译：只翻译选区，保留公式、代码、引用和数字；
- 页级双语：按 Block ID 对齐原文与译文，支持可关闭的双向同步滚动；
- 整篇翻译：Celery 逐页执行，原子缓存和断点续跑，完成后导出 Markdown 或自包含 HTML。

当前不提供 DOCX，也尚未生成保持原始 PDF 版式的双语 PDF。比赛要求允许 Markdown/HTML 或原位 PDF，因此当前实现选择可审计、可恢复的 Markdown/HTML 路径。

6. 检索推荐、引用图谱与研究综述

6.1 论文发现与追踪

系统支持题名、DOI 和 arXiv ID 查询，数据来自 Semantic Scholar、Crossref 与 arXiv API。导入时后端重新查询来源，只允许白名单 HTTPS PDF 域名，并校验重定向、大小与 %PDF- 文件头，防止浏览器传入任意下载地址。

arXiv 追踪使用 Celery Beat 定期刷新关键词和分类订阅。推荐分综合本地文献相关度、时间新鲜度和 GitHub 代码加分；点赞加入正向画像，点踩形成负向惩罚。补充搜索到的 GitHub 仓库只标记为“高相关实现”，不冒充作者官方代码。

6.2 局域引用图谱

正式截图规划	图 8：基石、桥接、衍生节点及 Future Work 双侧证据。
--------	-----------------------------------

此处将在最终公网版本录制后替换为真实界面截图。

图谱只分析当前库内文献。边优先按 arXiv ID 精确匹配，再使用规范化题名和作者年份等可解释分数。每条边保留 References 原文、页码和匹配理由。PageRank 与入度组合为基石分，并按局部拓扑区分基石、桥接、衍生和孤立节点。

这里的“基石论文”仅代表用户导入语料形成的局部网络，不等同于全领域影响力排名。

6.3 Future Work

系统从摘要、引言、讨论、结论、限制和 Future Work 区域提取证据，并按论文时间线组织。只有较新论文与旧方向存在较高概念覆盖，且在可能时存在引用关系，才标记“可能已有进展”；界面同时展示旧方向和后续证据，最终状态由用户确认。

7. 学术写作与数据可视化

7.1 无幻觉写作框架

用户输入研究 idea 并选择本地文献后，系统检索证据并生成 Abstract、Introduction 与 Related Work 框架。最终 References 不采用模型输出的书目文本，而是从本地 Document 与 PaperSource 重建作者、题名、年份、Venue、DOI、arXiv ID 和链接；字段缺失时警告并留空。

7.2 架构图脚本

系统将用户描述的节点与连线规范化为同一中间图，再输出 Mermaid、Graphviz DOT、TikZ 和 Matplotlib 四种脚本。预览和源码同时保留，便于论文、README 或答辩材料复用。

7.3 CSV 可视化

正式截图规划	图 10: 折线/柱状/三维雷达图、误差棒和数据约束 Caption。
--------	-------------------------------------

此处将在最终公网版本录制后替换为真实界面截图。

CSV 分析器执行编码、分隔符、字段类型、缺失值和数值有效性检查，支持：

- 折线图与柱状图；
- 多次观测聚合和误差棒；
- 三维雷达图；
- SVG 页面预览；
- 可复现 Matplotlib 脚本；
- 只依据实际数据趋势生成的 Figure Caption。

单次观测不会伪造不确定性；雷达图的层高只区分记录，不解释为额外数值维度。

8. AI 技术选型与优化策略

技术	选型理由	集成方式	失败策略
PyMuPDF	本地、速度快、保留字体和坐标	统一 Parser 接口输出 AST	页面诊断后对低文本页启用 OCR
Tesseract	无外部 API、可复现	chi_sim+eng 选择性 OCR	保留原页、标记解析边界
BGE-M3	中英文、多语义检索、1024 维	TEI OpenAI-compatible Embedding	查询降级 BM25，严格门禁判失败
BGE Reranker v2 M3	对有限候选做跨编码器精排	TEI/Cohere-compatible 接口，16 条微批	保留召回顺序并标记非 reranked
Qdrant	Dense/Sparse 命名向量和 Payload 过滤	Collection 按模型签名与维度隔离	可关闭向量检索
DeepSeek Flash	OpenAI-compatible、成本与延迟适合演示	独立 Responses Provider 适配器	抽取式 Provider，不编造缺失事实
Structured Outputs	限制自由文本不可审计问题	Claims、Evidence IDs、翻译 Block ID	Schema/引用错误有限重试后降级

优化重点包括：

- PDF 分批检查点减少长任务重跑；
- 只对低文本页 OCR，避免扫描整本原生 PDF；
- 表格重型分析只进入有可信提示的页面；
- Embedding 批量请求，Reranker 微批避免超过 TEI 限制；
- 不同向量模型使用不同 Collection，避免维度污染；
- Next.js standalone 和非 root 生产镜像降低演示资源占用；
- Lite/Standard 双模式区分低资源体验与完整语义验收。

模型权重保存在 Docker 命名卷，API Key 只存在被 Git 忽略的环境文件，均不提交到公开仓库。

9. 测试与验证

9.1 核心结果

测试项	当前结果	证据
Transformer v7→v1	8/8 检查通过；综合重复分 0.82，建议保留 v7	release-core-gate-acceptance-2026-09-27.md
扫描替代样本	15/15 页 OCR；36,674 字、8 位作者、23 个目录节点	同上；明确不是官方原始扫描件
541 页教材	8/8 检查通过；断点续跑；1,312,857 字	同上
七篇论文向量索引	1,405 个文本块与 Qdrant Point 逐篇一致	real-pdf-browser-expanded-acceptance-2026-09-27.md
BGE + DeepSeek 后端	连续三轮共 15/15 用例通过	numeric-fact-completeness-acceptance-2026-09-27.md
完整浏览器调用	两轮均 5/5；每轮 14/14 指定事实带页码锚点	同上
引用跳转与拒答	PDF 高亮跳转通过；无精确 CO ₂ e 证据时拒答	同上
前端回归	15 项测试、类型检查和生产构建通过	Stage 64、Stage 69 验收记录

9.2 评价原则

以上结果是固定论文、固定问题和固定金标的工程验收，不外推为开放域准确率。运行时完整回答与截图位于被忽略的 backend/tmp/，公开仓库保存可复现脚本、样本来源哈希和人工核对规则，不保存 API Key、模型权重或受限 PDF。

9.3 提交前仍需完成

- 获取组委会 pdf/ 原始目录并校验哈希；
- 复验官方 1706.03762v1_img.pdf 的机构、表格、图表和 OCR；
- 对官方 541 页教材做真实目录和表格质量抽检；
- 在最终公网环境完成上传、解析、问答、跳转和拒答闭环；
- 记录最终 Tag、SHA、演示地址、硬件和运行模式。

10. 部署、安全与可复现性

10.1 本地与标准模式

Windows 本地可使用：

```
.\scripts\start.ps1 -Mode lite  
.\scripts\start.ps1 -Mode standard -Gpu
```

Lite 模式不启动 BGE，适合首次体验；Standard 模式启动 BGE-M3 与 Reranker，用于完整 RAG 演示。停止服务默认保留数据库、PDF、索引和模型缓存。

10.2 公网部署策略

现有公网配置继续保留，暂不购买服务器。临近提交时再完成：

- 购买 Ubuntu 服务器并准备域名；
- DNS 指向公网 IP，安全组只开放 80/443 和受限 SSH；
- 在服务器本地填写 `.env.production` 与 `.env.bge`；
- 使用全新的 DeepSeek Key、随机数据库/MinIO 密码和评审密码哈希；
- 执行 `./scripts/deploy.sh standard-gpu start` 或适合硬件的模式；
- 从另一网络运行 `scripts/verify_public_demo.sh`；
- 手工完成核心业务闭环并做重启恢复演练。

生产 Compose 只由 Caddy 发布端口，自动 HTTPS、Basic Auth、安全响应头、日志滚动和数据卷均已配置。Basic Auth 是比赛入口门禁，不等同于应用级多用户隔离。

10.3 敏感信息

- `.env`、`.env.production`、`.env.bge` 均不提交；
- 聊天、日志或截图中出现过的 Key 必须撤销并轮换；
- 视频隐藏服务器 IP、内部日志、个人账号和密钥；
- 最终提交前扫描 Git 历史并从全新目录克隆启动。

11. 创新点

11.1 技术创新

- 贯穿全链路的证据坐标。AST、Chunk、Claim 和阅读器共用页码、Block ID 与 BBox，回答可回到原页而不是只给文献名。
- 检索降级与验收门禁分离。线上故障时允许 BM25 保持可用，但严格测试要求真实 reranked 证据，避免“静默降级仍显示成功”。
- 多文献公平取证。每篇论文独立召回、重排和预算分配，再形成全局证据，降低候选池被单篇文献垄断的问题。
- 生成后事实完整性复核。不只检查有没有引用，还检查用户明确要求且原文已经检出的数值是否进入最终声明。
- 长文档原子检查点。页面分片、Manifest 签名和原子替换支持 541 页任务中断恢复，并控制内存占用。
- 模型文本与真实 References 解耦。写作框架的书目由持久化元数据重建，模型无法凭空写入最终 References。

11.2 应用创新

- 问答证据、PDF 阅读、引用导航与翻译处于同一工作区；
- 版本冲突不自动覆盖，允许用户查看差异后决定；
- Future Work 同时展示旧方向与后续证据，把“是否已解决”留给研究者确认；
- 图表 Caption、架构图源码和论文框架均输出可编辑、可复现材料，而不是不可追溯图片。

12. 已知边界与后续计划

- 组委会原始扫描 PDF 尚未取得，现有 OCR 成绩来自可复现替代样本；
- 复杂公式仍是 LaTeX 候选，未接入专用数学 OCR；
- 复杂合并单元格、旋转表格和弱信号跨页表格需要专用适配器；
- 双语导出当前为 Markdown/HTML，原位排版 PDF 尚未完成；
- 公网模式当前是共享评审门禁，不具备多租户文献所有权；
- 生成模型存在随机性，固定金标通过不能等同任意问题准确；
- 真实服务器、域名和最终外网验收将临近提交时完成，以减少空置费用。

后续优先级：官方样本复验 → 公网部署与外部验收 → 技术 PDF 排版 → 视频录制 → 最终 Tag 与材料哈希冻结。

13. 成品 PDF 编排建议

页码预算	内容
1	封面
2	摘要与关键词
3	目录
4-5	项目概述、需求分析、六模块映射
6-8	总体架构、数据流、Agent Harness
9-12	PDF 解析、OCR、长文档与去重
13-16	RAG、多文推理、引用白名单与阅读器
17-19	推荐、图谱、综述、写作与可视化
20-21	AI 选型、优化与失败降级
22-23	测试结果与复现方式
24	部署与安全
25	创新点、边界和展望
26	最终链接、版本信息与参考资料

最终排版时优先放置以下截图：版本去重提示、Document AST/目录、带证据回答、PDF 原页高亮、多文比较矩阵、双语联动、引用图谱、写作框架、三维雷达图和公网门禁。每张截图必须带简短结论，避免只展示界面。

14. 仓库内参考资料

- 总体架构: docs/architecture.md
- 核心交付门禁: docs/release-core-gate-acceptance-2026-09-27.md
- 数值事实完整性: docs/numeric-fact-completeness-acceptance-2026-09-27.md
- 真实 PDF 浏览器闭环: docs/real-pdf-browser-expanded-acceptance-2026-09-27.md
- 扫描 PDF OCR: docs/scanned-pdf-ocr-acceptance-2026-09-13.md
- 541 页长文档: docs/long-document-acceptance-2026-09-14.md
- 公网部署: docs/public-deployment.md
- 比赛交付清单: docs/competition-delivery-checklist.md