PAPERPILOT

原文证据驱动的科研助手 Agent 系统

面向 PDF 细粒度解析、抗幻觉问答、多文推理、双语阅读、引用图谱与研究材料生成的可复现系统

文档状态	技术内容核对版（公网待上线）
仓库	github.com/Sana-114/PDF-AGENT
在线演示	本地演示已检查；公网部署未验收
代码基线	a26acbc

2026-10-08 · 技术内容核对版

目录

摘要	3
1. 项目概述与需求分析	3
2. 系统总体架构	4
3. PDF 管理与细粒度解析	5
4. 抗幻觉问答与多文推理	6
5. 版式阅读与双语翻译	7
6. 论文发现、追踪与引用筛选	8
7. 引用图谱、综述与未来方向	8
8. 写作辅助与数据可视化	10
9. AI 选型、集成与优化	11
10. 测试、证据与复现	11
11. 部署、安全与交付	12
12. 创新点、总结与展望	12
13. 验收资料索引	13

摘要

PaperPilot 将论文阅读、问答、翻译、引用关系和研究材料整理放在同一工作区。系统先把 PDF 解析为带页码、块编号和坐标的 Document AST，再检索相关片段供模型组织回答。前端呈现回答声明和原文出处，并提供 PDF 原页跳转。标准模式使用 BGE-M3、BGE Reranker 和已配置的 DeepSeek Flash；抽取式路径可以在不调用外部模型时整理原文。

系统覆盖六类比赛任务的主要流程。本轮新增引用句作用筛选、Future Work 人工核验持久化和本地录制检查。239 项后端离线测试、20 项前端测试、类型检查及生产构建通过；六个真实界面场景完成 1920×1080 检查。历史五案例三轮模型成绩与新版七案例待验收状态分开记录。解析出的公式是候选 LaTeX，OCR 专有名词、复杂表格和研究判断仍需人工核对。

关键词：科研助手；Document AST；RAG；证据定位；多文推理；局域引用图谱。

1. 项目概述与需求分析

1.1 使用场景

用户上传论文，检查版本和解析状态，在原始版式中阅读与翻译，围绕选定论文提问或比较方法，沿参考文献寻找后续阅读材料，再通过图谱、综述、写作框架和图表整理研究成果。系统的重点是减少用户在 PDF、搜索、对话和写作工具之间反复搬运上下文的成本。

1.2 比赛要求映射

模块	实现路径	验收边界
PDF 管理与解析	批量上传、CRUD、正文指纹、版本建议、OCR、结构节点、检查点	官方扫描件未复测；公式不是数学 OCR 真值
单篇 / 多篇问答	BM25、向量召回、重排、DeepSeek、逐声明引用和拒答	历史固定案例通过，不等同开放域准确率
阅读与翻译	PDF.js、目录、引用双向导航、划词、页级双语、同步滚动、Markdown / HTML	作者年制自动链接尚未覆盖；原位 PDF 可选增强未实现
发现与推荐	题名 / 标识检索、安全导入、引用作用、arXiv 订阅、代码加分、反馈	引用作用是保守线索；多用户隔离未实现
图谱与综述	库内引用、局部 PageRank、证据综述、未来方向和人工记录	局部角色不是全领域影响力；人工作出是否解决的判断
写作与可视化	论文框架、真实来源书目、四种图脚本、CSV 图表和图注、学术翻译	不替代论文论证、统计检验或翻译审稿

1.3 非功能要求

长任务异步执行并可恢复；外部服务失败有明确降级和警告；密钥不进入前端、Git 或截图；运行配置、样本来源、测试规则与 Git 阶段可追溯。界面以问答、文献库、查找论文、研究脉络和研究产出五个入口组织六模块，避免把所有工具同时铺满首页。

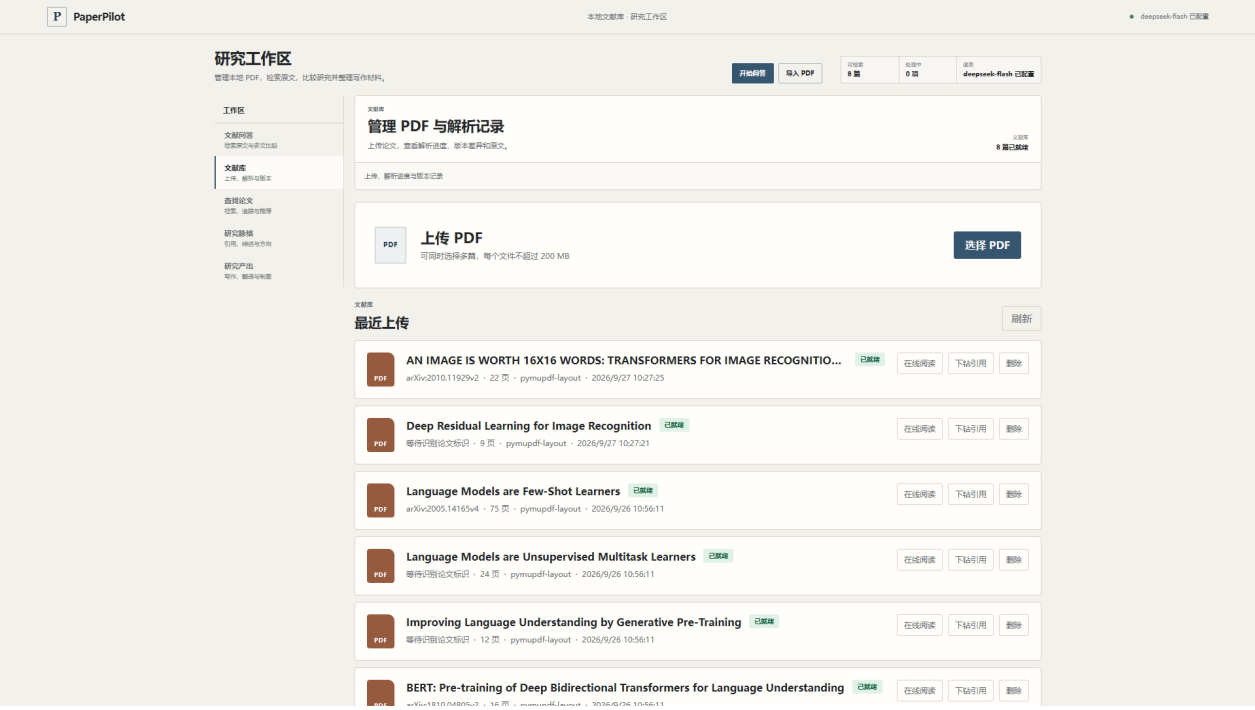


图 1：真实文献库页面。显示解析状态和原文入口；不是静态原型。

2. 系统总体架构

2.1 分层设计

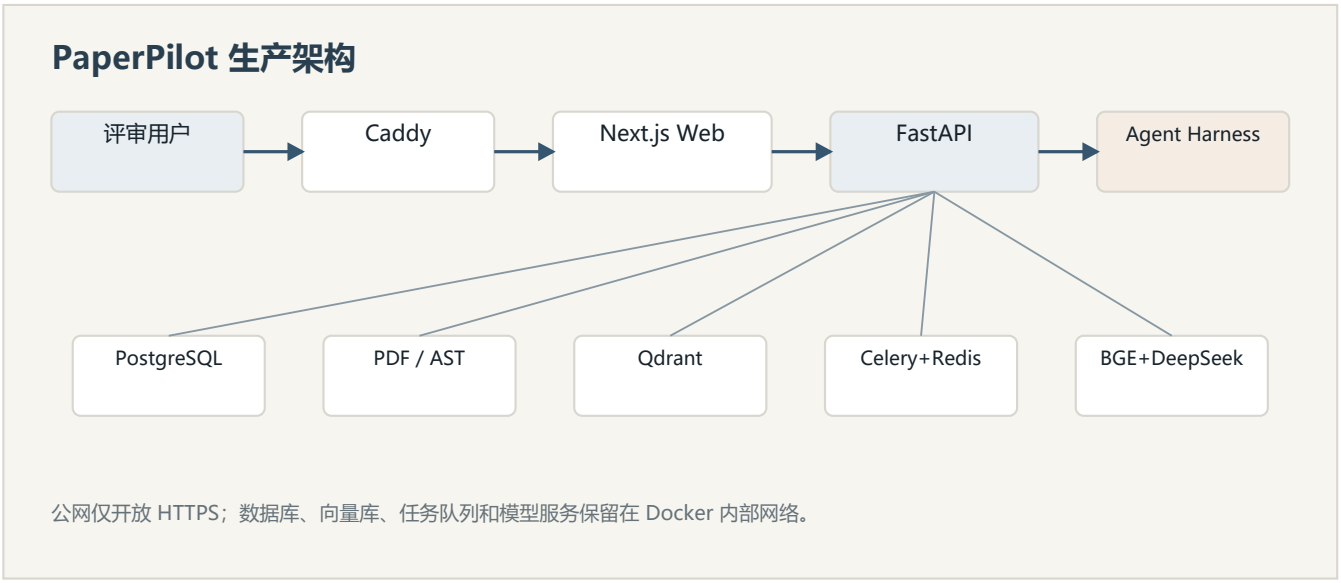


图 2：系统总体架构（矢量绘制）。

Next.js / React 负责交互和阅读；FastAPI 提供业务接口；Celery Worker / Beat 处理解析、翻译与订阅刷新；PostgreSQL 保存状态，文件卷保存 PDF / AST，Qdrant 保存向量。MinIO 配置作为基础设施保留，当前 PDF 上传实际使用本地命名卷存储，不把配置存在当成已接入对象存储。

图中的 Caddy 是已准备的公网方案，尚未在购置的公网服务器完成验收。本机演示直接使用前端 3300 和 API 8000，不能将它标成公网在线地址。

2.2 核心数据流

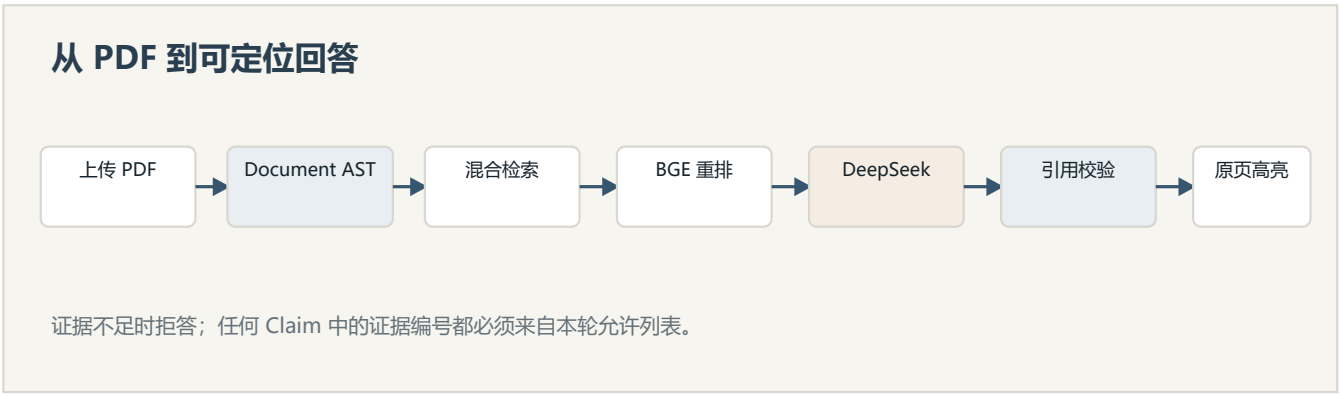


图 3：核心数据流（矢量绘制）。

2.3 Agent Harness 与 Skills

Harness 是受业务流程约束的任务编排器，并非无限自治工具调用。Skill Registry 为概要、目录、表格、图表、公式、参考文献和证据检索定义结构化输入与输出。Trace 标识检索与生成路径；生成、证据门控和输出检查分离，便于发现是解析、检索还是模型回答出错。

3. PDF 管理与细粒度解析

3.1 路由与 AST

均匀抽样页面的文本密度区分原生、扫描、混合与空文档。PyMuPDF 保留页面文本、字体和坐标；低文本页选择性执行 Tesseract 中英文 OCR。统一 AST 包含标题、作者、机构、摘要、三级标题、页面块、表格、图区域、公式候选、参考文献与附录。后续工具共享这一解析结果。

3.2 版式和复杂内容

双栏阅读顺序依据几何位置重排；表格使用矢量网格或可信图注 / 列锚点；跨页表格合并要求相邻页、列边界一致和续表提示。扫描图区域采用受限栅格定位，不将整页扫描背景算作论文插图。公式保存原文本和 BBox，并进行明确数学符号的 LaTeX 规范化，不能保证复杂矩阵、分式和二维表达式完整还原。

3.3 版本处理

SHA-256 识别文件完全重复；arXiv ID、题名和正文指纹重合形成不同版本候选。提醒后由用户保留原版、替换或两版并存。AST 对比输出标题变化与可能新增 / 删除段落，并保留来源。此处正文指纹属于内容相似性方法，不是专门训练的版本语义差异模型。

3.4 长文档与恢复

默认每 25 页原子保存检查点，绑定文件 SHA、解析器版本和批大小。真实 541 页教材历史验收在 50 页模拟中断，恢复后第一个完成事件是第 75 页；最终 1,312,857 字，Python 分配峰值 45.11 MB、RSS 峰值 298.58 MB。该测试证明吞吐与恢复，不证明教材全部内容正确：当次教材表格抽取为零，复杂表格仍有缺口。

3.5 最新扫描结果

第 73 阶段的自制 15 页无文本层替代样本抽取 36,624 字、8 个姓名项和精确三家机构，耗时 87.308 秒、Python 分配峰值 49.09 MB。机构为 Google Brain、Google Research 和 University of Toronto。仍有 Lukasz 被 OCR 转录为 Fukasz 的字符错误，不能把姓名数量正确当成全部姓名准确。组委会同名扫描原件未取得；已有入库文档需重新解析才能采用新版解析器。

4. 抗幻觉问答与多文推理

4.1 检索与模型职责

BM25 补足精确术语；Qdrant Dense / Sparse 和融合召回语义候选；BGE Cross-Encoder 对有限候选重排。DeepSeek 负责组织已有证据、比较与生成语言表达，不负责作为事实数据库。BGE 故障可降级，但标准模式验收必须获得实际 reranked 证据，不能静默降级后记为通过。

4.2 声明、引用与定位

每轮证据重新编号，Claim 必须引用允许的编号。校验编号、结构与数值；EvidenceAnchor 保存文献、页码、块、BBox 和摘录。合法引用并不自动证明声明含义正确，因此还需金标核验和人工审校。SSE 先校验最终结果再渐进展示，不宣称直接透传上游 Token。

4.3 多文比较和拒答

每篇论文分别分配取证预算，避免长论文占满候选。枚举的比较维度独立检索，数值完整性检查避免原文已经检出而最终漏写。缺少精确双来源数据时拒绝比较指定精确量，不把 TPU 信息推成 GPU 配置，不估算未报告的碳排放。

4.4 当前真实模型验收状态

历史五案例三轮共 15 次案例运行通过；后续历史浏览器两轮各五案例、14 条指定事实验收有记录。第 72 阶段新数据集增加 LayerNorm 双来源和未报告 GPU 的拒答，共七案例、17 条事实，三轮计划为 21 次案例运行。此次执行被安全审批拦截，尚无新版真实模型成绩；补充 / 重试可能导致 API 请求数多于案例运行数。

5. 版式阅读与双语翻译

PDF.js 原生展示页面，目录导航和百分比坐标覆盖层支持缩放后的证据定位。数字与真实字母书目标签可连接 References，返回点击位置或遍历上一 / 下一处引用；未知标签不生成链接。作者年制正文引用尚未实现完整自动双向链接。

划词 / 选段翻译保护公式、代码、引用和数字；页级译文按 Block ID 对齐，并提供可关闭的双向同步滚动。后台整篇翻译逐页缓存和续跑，输出 Markdown / 自包含 HTML。比赛允许这些格式，DOCX 不属于当前功能；保持原位 PDF 仍是未实现的可选增强。逐页功能存在不等同整篇翻译质量已完成学术审校。

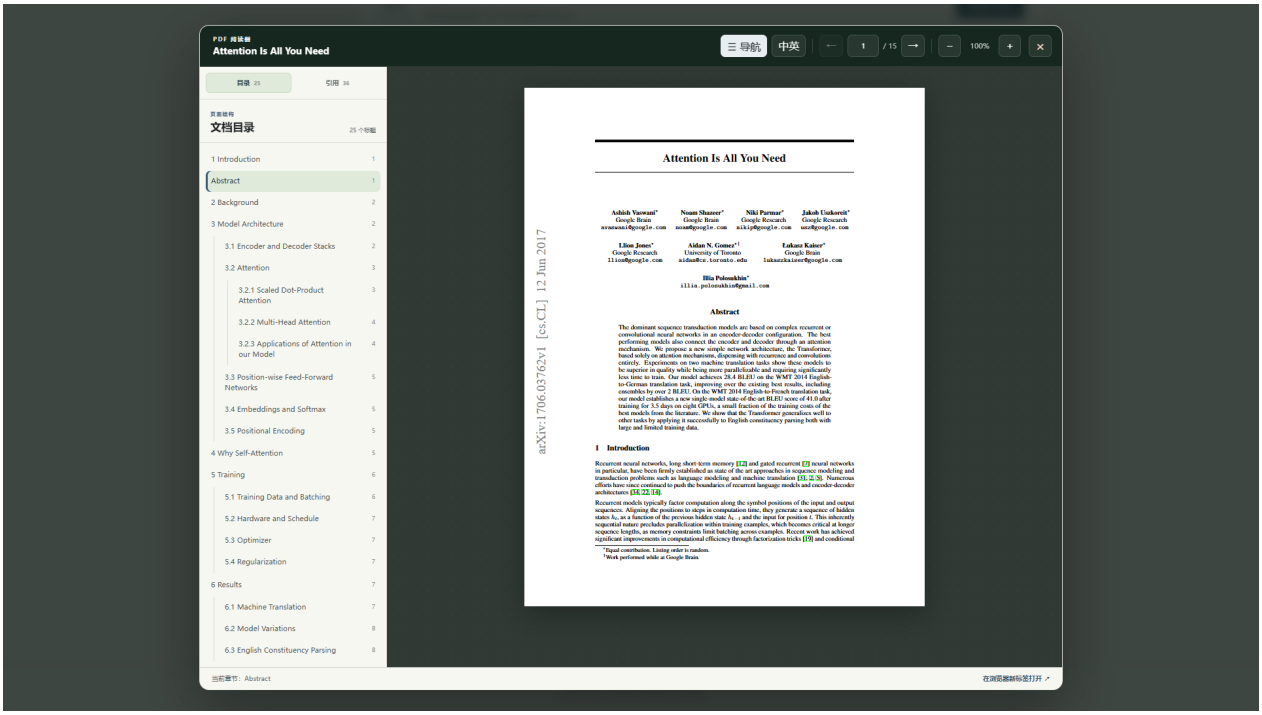


图 4：Transformer 原生 PDF 与三级目录。截图来自公开 arXiv:1706.03762v1，论文著作权归作者。

6. 论文发现、追踪与引用筛选

6.1 发现与安全导入

题名、DOI 和 arXiv 标识查询 Semantic Scholar、Crossref 与 arXiv。导入时后端重新解析来源，限制 HTTPS PDF 域名、重定向、体积及 PDF 文件头，避免任意地址下载。搜索匹配分反映书目身份，不代表论文质量。

6.2 引用正文作用

从实际引用偏移抽取所在句，保存页、块、BBox 和摘录。方法采用 / 扩展及实验基线优先；背景和未知不默认勾选；仅有泛指语境的条目在推荐模式暂不下钻，用户仍可按原顺序查看或显式选择。引用次数和题名匹配不能替代作用证据。这是保守规则筛选，不是对作者动机或“应付式引用”的事实判定，复合句和隐式引用可能误判或漏判。

6.3 arXiv 推荐

Celery Beat 定期刷新订阅，无需依赖 Sickle。排序结合本地相关度、时间、代码链接与点赞 / 踩反馈。搜索到的相关 GitHub 实现不自动冒充作者官方代码。当前共享文献库及评审门禁不是多用户数据隔离系统。

7. 引用图谱、综述与未来方向

7.1 局域拓扑

引用边按标识优先，再以规范题名等可解释匹配建立；保留参考条目和来源页。PageRank、入度等给出局部基石、桥接、衍生和孤立角色，不外推全领域影响力。本次界面为八节点文献库，不能当作二十篇真实图谱专项成绩。

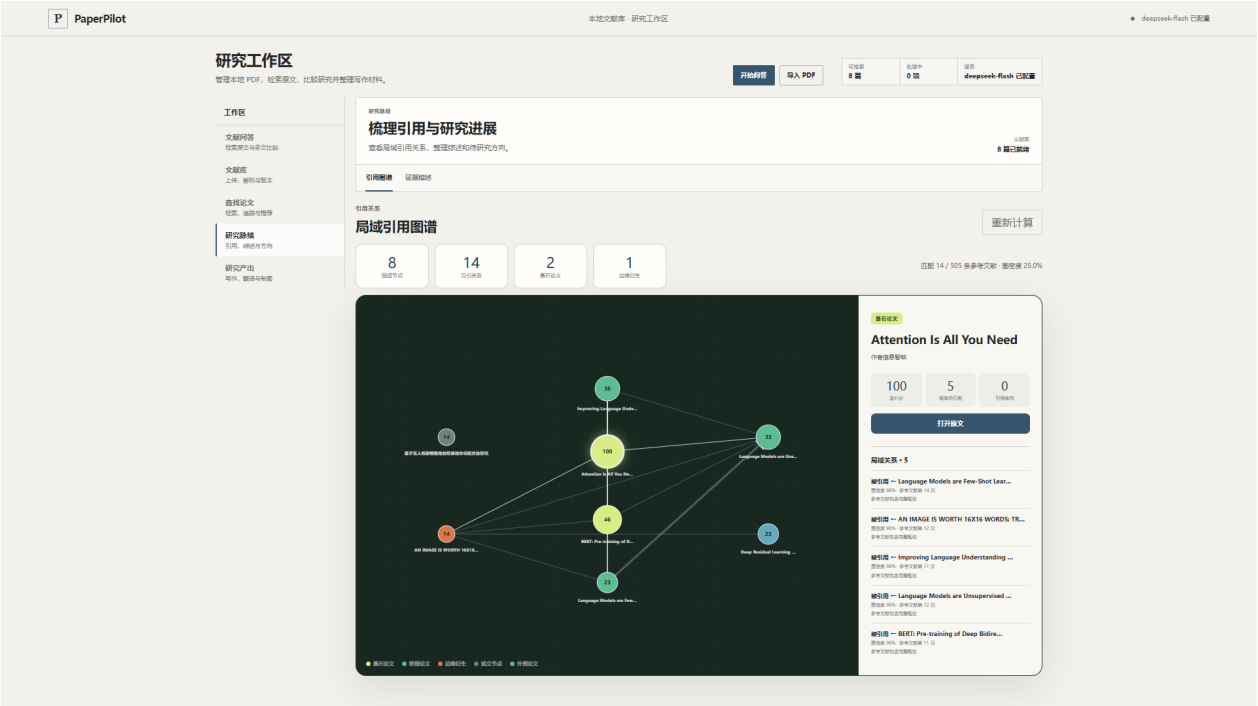


图 5：真实局域引用图。角色取决于本次导入文献范围，不代表全领域排名。

7.2 Future Work 核验

Future Work 是论文提出的未来工作或未解决问题。系统提取相关段落，按较新论文的时间和主题证据提示可能进展，不自动宣称解决。方向 ID 绑定原文，记录继续探索、待核验及人工确认已有解决证据。确认需要更晚论文中的真实连续摘录、页码和块，拒绝同篇、旧年份或未知年份依据。

已确认方向不作为开放方向推荐，但原文和记录仍可查。重生成恢复判断，证据变更则不再据此排除。人工确认是研究者的判断，并非系统证明科学问题已解决；目前保留最新记录，没有多用户审计历史。联网搜索只能提供候选，须先导入并解析后核查原文。

7.3 原文整理模式

用户可以选择不调用 LLM，直接整理来源片段与未来方向；此模式明确显示 extractive。本地检查保存的是待核验流程记录，不是科学结论。生成式中文综述仍需要真实模型调用与审校。

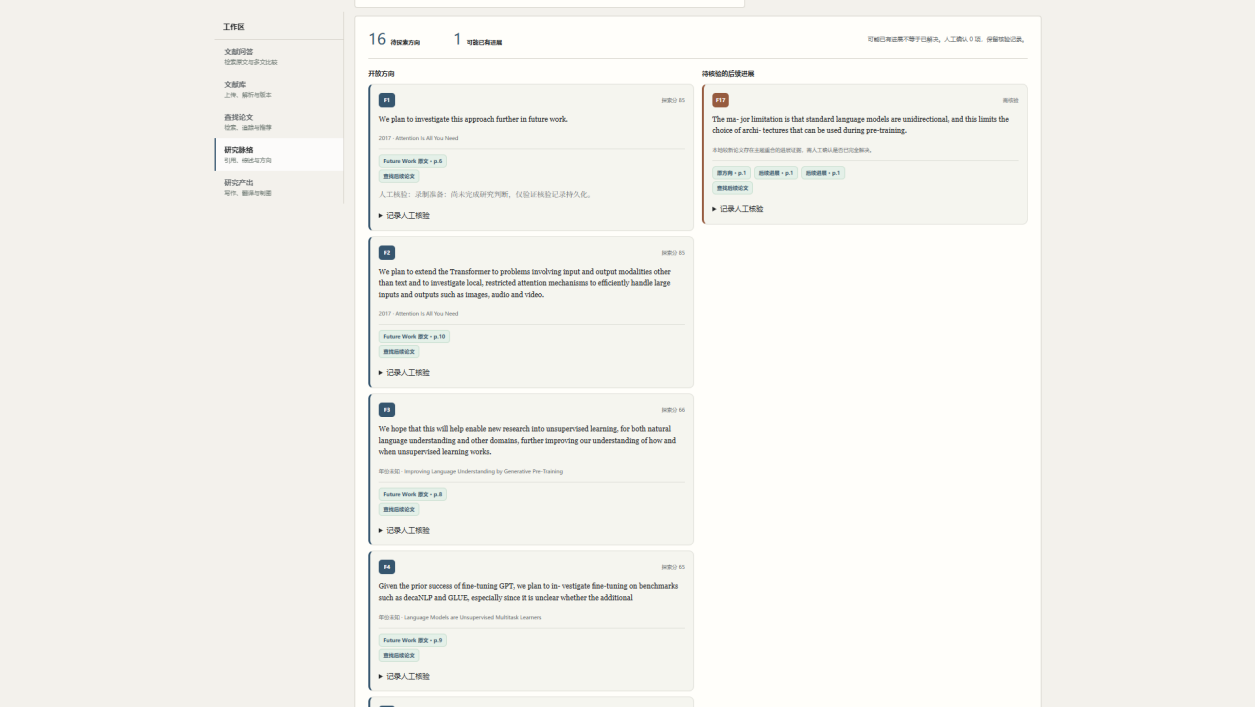


图 6：未来方向与原文入口，展示抽取式模式；不能把该截图当成 DeepSeek 生成成绩。

8. 写作辅助与数据可视化

8.1 论文框架和真实 References

idea 与选定文献经检索后组织 Abstract、Introduction、Related Work。书目由 Document / PaperSource 重建，不采用模型自由编写的书目。缺失年份、作者或 DOI 等字段需提示，并不因此声称已拥有完整出版物信息。提出新论点和实验设计仍需研究者审查。

8.2 拓扑脚本

描述的节点与连线转为统一图结构，输出 Mermaid、Graphviz、TikZ 和 Matplotlib 四种脚本。预览和源码可编辑；这个确定性转换路径无需 LLM，也不保证所有第三方工具环境中的渲染效果。

8.3 CSV 图表与图注

检查编码、分隔符、列类型、缺失和非有限数值，支持表格、折线、柱状、聚合 / 误差棒、三维雷达和 SVG / Matplotlib 输出。Caption 只描述实际统计趋势，不推断因果或显著性。雷达透视层高区分记录，不增添数据维度；示例三种方法的数值是界面演示数据，不是项目模型准确率。

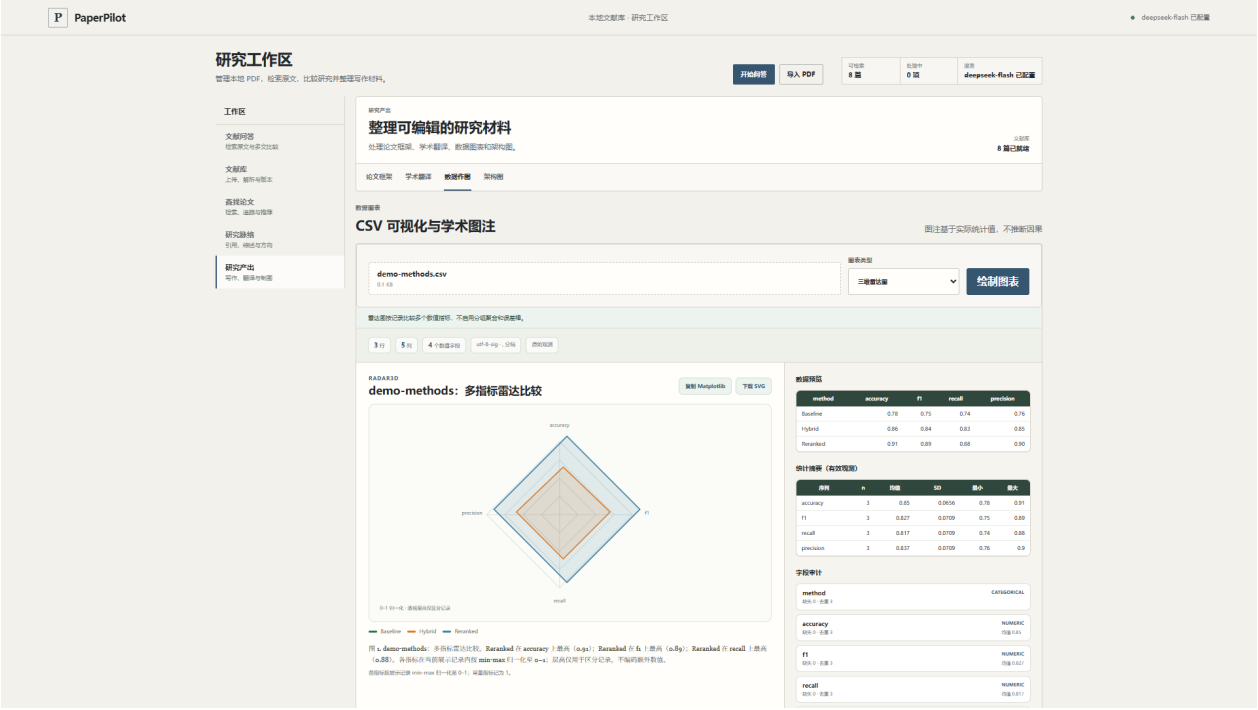


图 7：合成 CSV 的雷达图、统计表和图注。数据仅用于演示，不作为 RAG 性能结论。

8.4 学术翻译

中英翻译支持术语表、代码 / 公式 / 数字保护和审校草稿。模型负责学术语言表达，不能取代领域专家；长篇译文、术语一致性和特殊版式仍需人工抽检。

9. AI 选型、集成与优化

技术	本项目作用	集成与降级
PyMuPDF / Tesseract	保留几何位置，补充低文本页 OCR	Parser 接口统一 AST，缺包明确报错
BGE-M3	语义 embedding 召回	TEI 接口，本地模型缓存，不入 Git
BGE Reranker v2 M3	问题与候选片段联合重排	有限微批，失败标记非标准检索
Qdrant / BM25	语义与精确召回	模型签名隔离向量库，故障降级可辨识
DeepSeek Flash	证据回答、语言组织和翻译	Provider 适配、结构解析、有限重试 / 抽取式降级
Harness / Schema	约束工具、声明和引用	Trace、白名单及数值审计，可定位失败阶段

优化包括按页检查点、低文本页 OCR、受限重型表格分析、Embedding 批量、Reranker 微批、缓存译文和按论文预算取证。CPU / GPU 标准模式与 Lite 模式区分部署成本；不把 Lite 的确定性向量当成 BGE 语义质量。新功能的规则与人工决策不必调用 LLM，有助于成本、延迟和来源核对。

10. 测试、证据与复现

10.1 分层成绩

日期 / 阶段	验证项	结果与局限
9 月，第 65 阶段	v7→v1、真实 541 页教材	各 8/8 工程检查；不代表全部抽取质量
9 月，第 66 阶段	历史五案例模型与浏览器	后端三轮 15/15；浏览器两轮各 5/5、14 事实
10 月，第 73 阶段	六篇原生、扫描替代样本	原生 144 页 6/6；扫描三家机构精确，仍有姓名错字
10 月，第 76 阶段	离线回归与前端	后端 239；前端 20；Ruff、类型与生产构建通过
10 月，第 76 阶段	本地真实浏览器录制路径	六场景截图、无页面异常；不调用外部模型
第 72 阶段新版	七案例三轮	计划 21 次案例运行；此次审批拦截，未出成绩

10.2 可复现原则

源 PDF 清单记录来源与 SHA，数据集独立于模型，金标要求指定来源与页码。缺少案例、模型改变和不安全拒答不计稳定通过。机器 JSON、模型答案及下载 PDF 位于忽略目录，公开仓库保存脚本、规则、截图与验收说明。截图均为实际页面返回，没有合成回答或替换 API 数据。

10.3 复现命令

```
# 在 frontend 目录，复现不调用外部 LLM 的页面检查
node e2e/recordingReadiness.mjs
# 明确授权公开论文摘录外发、配置有效 Key 后再运行
pwsh -File scripts/run_real_pdf_comparison_e2e.ps1 -Gpu -Rounds 3
```

第二条在仓库根目录运行。完整离线测试使用后端开发依赖及中英文 OCR 语言包；运行脚本 README 已提供安装步骤。自动门禁是固定样本工程检查，不是任意问题的正确性证明。

11. 部署、安全与交付

11.1 本地运行

Docker Desktop 启动后，仓库根目录执行 `scripts/start.ps1 -Mode standard -Gpu`，无 NVIDIA 环境移除 GPU 选项；Lite 使用 `-Mode lite`。本机当前前端 3300、API 8000。启动检查区分端口占用 / Windows 保留端口；停止默认保留数据卷。先恢复数据库 / 队列依赖再诊断后端，不能仅因前端容器健康就认定全链路正常。

11.2 公网方案保持不变

生产 Compose、Caddy HTTPS、评审门禁、备份和外网检查脚本已准备。临近提交再购置服务器与域名，配置 DNS、仅开放必要端口，使用新 Key 和随机密码部署，并从另一网络验证上传、解析、问答、原页跳转和拒答。当前没有公网地址或线上验收成绩。

11.3 敏感数据和最终材料

环境文件不入 Git，模型权重保存在命名卷。聊天中暴露过的 Key 应撤销并重新生成。LLM 会将检索摘录发送到配置的模型服务，应获得用户授权并避免私有文献外发。本次新版模型验收暂停于此授权限制，未绕过审批。提交前补齐真实团队信息、Public / 评审权限、正式 Tag、≤30 页 PDF、5-8 分钟 1080p MP4、公网 URL 与体验方式，再冻结材料哈希。

12. 创新点、总结与展望

12.1 技术与应用创新

贯穿解析、检索、声明和阅读的证据坐标；标准检索验收与故障降级分离；按论文和维度公平取证；已检出数值的输出完整性复核；长文档原子检查点；模型生成书目与真实元数据解耦。新增引用身份 / 作用分离、基于可复验原文的方向人工记录，使用户能检查判断依据，而不只看到流畅文本。

12.2 未覆盖的核心边界

官方扫描原件、OCR 姓名字符、复杂数学和教材表格仍有缺口；作者年制引用导航、应用级多用户隔离尚未完成；引用作用规则可能漏判，人工确认不是自动科研证明；整篇翻译和新 idea 的论证需要学术审校。七案例真实模型三轮、清洁环境启动、公网 / 正式视频及最终 Tag 仍未完成，不能声明比赛全部验收通过。

12.3 有限收尾顺序

明确授权仅七篇公开论文摘录发送 DeepSeek → 执行一次七案例三轮 → 只复测失败相关项 → 录制完整本地演示 → 官方数据复测 → 临近提交公网部署、补录门禁 / URL → 更新真实团队与最终成绩 → 材料冻结。不无限扩展测试集，不在缺少真实结果时填写通过数字。

13. 验收资料索引

所有路径相对仓库根目录。机器结果与 PDF 下载文件不进入 Git；以下说明保存复现入口、验收条件和实际结果。

用途	仓库文件
安装与架构	README.md；docs/architecture.md
公网部署方案	docs/public-deployment.md
历史核心门禁	docs/release-core-gate-acceptance-2026-09-27.md
历史数值完整性	docs/numeric-fact-completeness-acceptance-2026-09-27.md
扫描机构元数据	docs/scanned-metadata-acceptance-2026-10-08.md
引用正文作用	docs/citation-context-acceptance-2026-10-08.md
Future Work 人工核验	docs/future-work-review-acceptance-2026-10-08.md
本地录制路径	docs/recording-readiness-acceptance-2026-10-08.md
交付清单	docs/competition-delivery-checklist.md
视频分镜与解说	docs/demo-video-script.md

本报告记录项目实现，不将截图中论文内容当作作者原创成果。公开论文来源与哈希详见 `docs/pdf-regression-corpus.json`；原始论文权利归各作者 / 出版方，下载文件不随项目代码提交。